

# MM5425 商业分析

---

WEEK 3 LECTURE – HYPOTHESIS TEST, DATA MINING PROCESS

# 第三课 内容

---

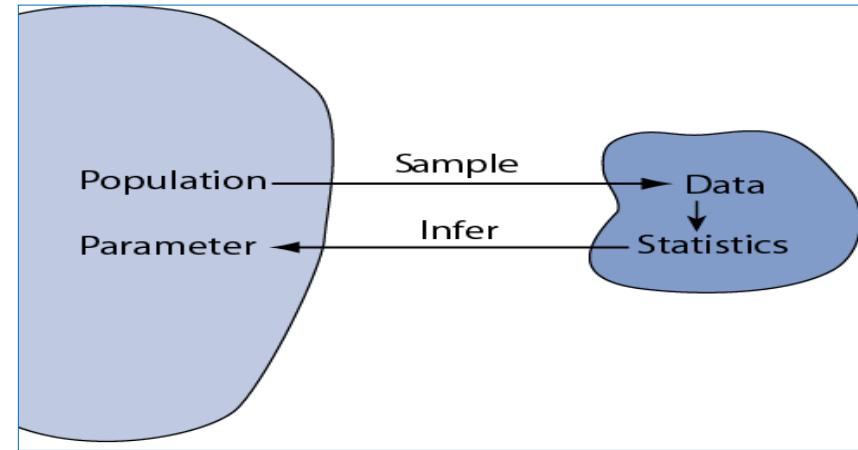
- 假设检验 Hypothesis Testing
  - 原假设和备择假设 Null and alternative hypothesis
  - 统计检验 Test statistic
  - P值 P-value
  - 显著性水平 Significance level
- 跨行业数据挖掘流程 (CRISP-DM):
  - I. 业务理解 Business Understanding
  - II. 数据理解 Data Understanding
  - III. 数据准备 Data Preparation
  - IV. 建模 Modelling
  - V. 评估 Evaluation
  - VI. Deployment

# 假设检验

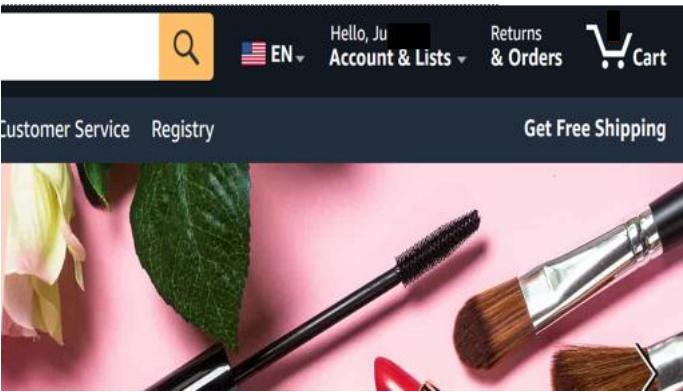
# Hypothesis Testing

---

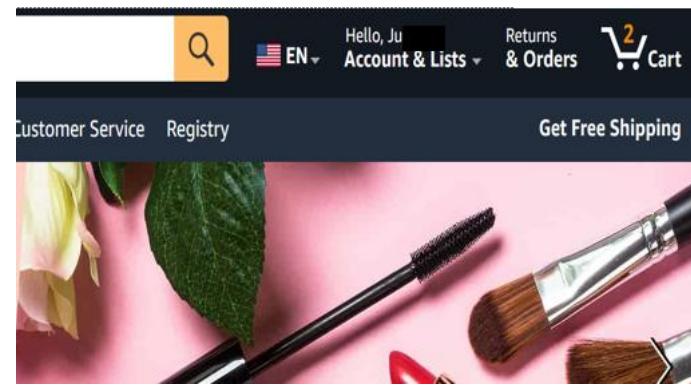
INFERENCE FROM SAMPLE



# 例子：网站优化



A

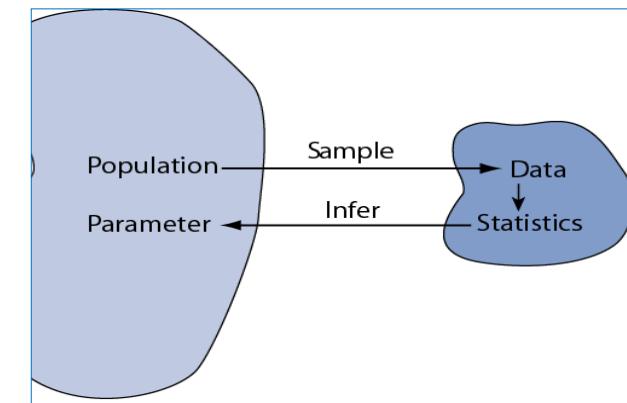


B

网页设计A和网页实际B，哪一个更优？

# 假设检验简介

- 假设检验是一种统计方法来证明某事是否正确.
- 例子:
  - 新网页比旧网页好吗?
  - 新的营销活动比其他营销活动更好吗?
- 当从总体中抽取随机样本时，所获得的信息可用于对总体特征进行推断



# 假设检验步骤 Hypothesis Testing Steps

---

1. 制定原假设和备择假设。
2. 选择合适的检验统计量，并确定拒绝或保留原假设的标准。
3. 计算检验统计量的  $p$  值，即在原假设成立时观察到该统计量值的条件概率。
4. 决策：如果统计量的值落在临界区，则拒绝原假设，否则接受原假设。

# 1: 原假设和备择假设

---

原假设 ( $H_0$ ) 是当前持有的信念

备择假设 ( $H_1$ ) 认为 “ $H_0$  为假”

在检验假设时，我们会确定它是单尾检验还是双尾检验.

双尾Two-tailed: 参数发生变化

$$H_0 : \mu = 6.7$$

$$H_1 : \mu \neq 6.7$$

单尾One-tailed: 参数变大或者变小

$$H_0 : \mu = 6.7$$

$$H_1 : \mu > 6.7$$

or

$$H_0 : \mu = 6.7$$

$$H_1 : \mu < 6.7$$

# 例子 1: 单尾检验 One-sided Testing

---

过去五年，该店平均顾客满意度为6.7。店铺改造后，经理有理由相信该店顾客满意度会更高。

原假设 **Null hypothesis**  $H_0: \mu = 6.7$  (“没有分别”)

备择假设 **The alternative hypothesis**  $H_1: \mu > 6.7$  (“客户更加满意”)

# 例子 2: 双尾检验 two-sided Testing

---

陈述——男生和女生毕业时的平均薪资是不同的

$$H_0: \mu_m = \mu_f$$

$$H_A: \mu_m \neq \mu_f$$

其中， $\mu_m$  和  $\mu_x$  分别表示男生和女生在毕业时的平均薪资。

## 2: 检验统计量 Test Statistic

---

Z检验：如果总体方差已知。通常用于样本量大于30的情况：

$$\text{z-statistic} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

T检验：如果总体方差未知。通常用于样本量小于30的情况

$$t = \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}}$$

### 3: 计算P值 $p$ -value

---

$p$  值回答的问题是：在原假设 ( $H_0$ ) 为真的情况下，观察到当前检验统计量或更极端结果的概率是多少？

因此， $p$  值是支持原假设的证据。 $p$  值越小，反对原假设的证据就越强。

所以， $p$  值很小  $\Rightarrow$  有强有力的证据拒绝原假设 ( $H_0$ ) 。

# 3: 计算p值 p-value

## 单样本检验示例

$H_0: \mu = 6.7$  (“没有不同”)

$H_1: \mu \neq 6.7$  (“客户满意度有不同”)

假设历史平均满意度评级为 6.7，  
而 196 名新随机样本的平均满意度评级为 7.3，标准差为 2.8.

fx	=T.TEST(A2:A197,B2:B197,2,3)			
1	A      B      C      D      E Sample Satisfaction Historical Average Ratings			
2	9.8	6.7	p-value	0.0026
3	9.0	6.7		

# 3: 计算p值 p-value

---

双样本检验示例

硕士毕业生的平均年薪高于非硕士毕业生.

$$H_0 : \mu_{MS} = \mu_{not\ MS}$$

$$H_1 : \mu_{MS} > \mu_{not\ MS}$$

		=T.TEST(A2:A45, B2:B45, 1, 3)		
A	B	C	D	E
Salaries of those with MS degree	Salaries of those below MS degree			
\$ 798,237.15	\$ 437,407.78		p-value	1.83446E-16
\$ 728,427.18	\$ 588,775.21			
\$ 628,223.40	\$ 478,610.76			
\$ 780,153.02	\$ 565,479.37			

## 4: 决策标准——显著性水平

---

- 显著性水平，通常用  $\alpha$  表示，是根据计算得到的  $p$  值来决定是否拒绝原假设的判断标准。
- 显著性水平也定义了置信水平。

补充说明：

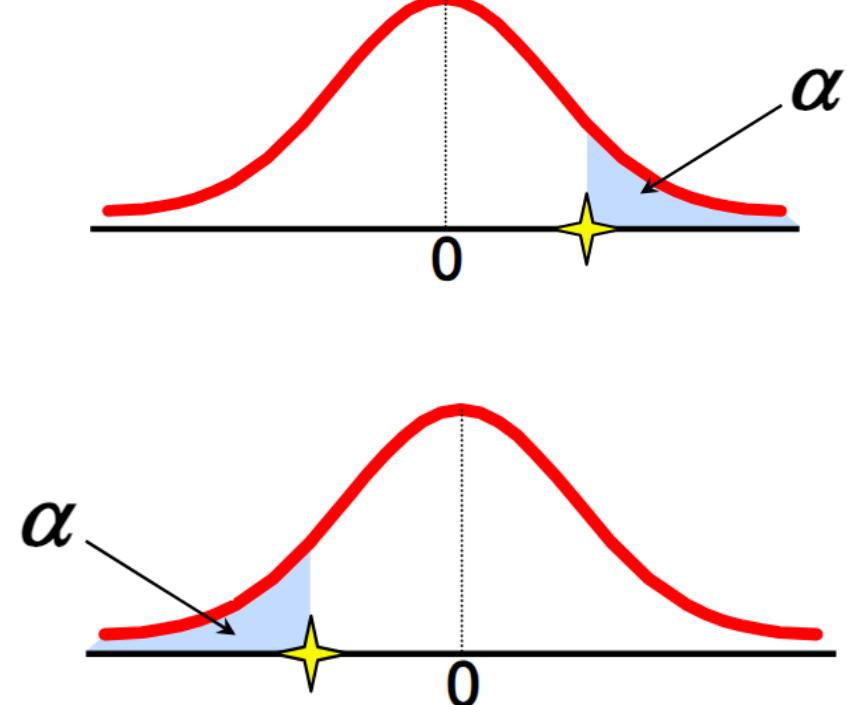
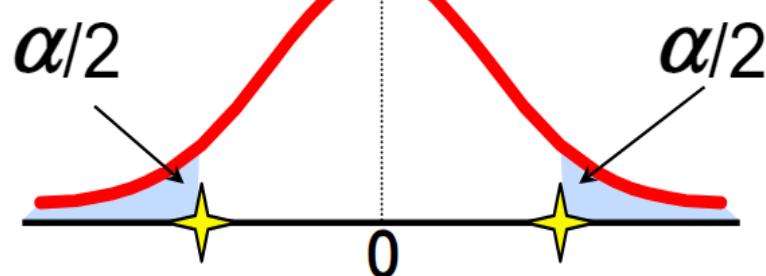
置信水平 = 1 - 显著性水平 ( $\alpha$ )。

例如，显著性水平为 0.05 时，置信水平为 95%。：

# 4: 决策标准

- 显著性值  $\alpha$  是  $p$  值的最大阈值

- Reject  $H_0$  when  $p \leq \alpha$
- Retain  $H_0$  when  $p > \alpha$



# 网站 A/B 测试示例

---

下图显示了网站A和B的销售额.

取  $\alpha = .05$ ,  $p = 0.0339$ ,  $p < \alpha \Rightarrow$  拒绝  $\text{reject } H_0$

结果显示网站 B 的销量比网站 A 有显著提高。

<b>Mean</b>	127.7358	128.1242
<b>Variance</b>	12,533.4069	12,620.1956
<b>Observations</b>	750,706	749,294
<b>Hypothesized Mean Difference</b>	0.0000	
<b>Mean Difference</b>	0.3884	
<b>% Mean Difference</b>	0.0030	
<b>P-value</b>	0.0339	

# 跨行业数据挖掘标准流程 (CRISP-DM)

---

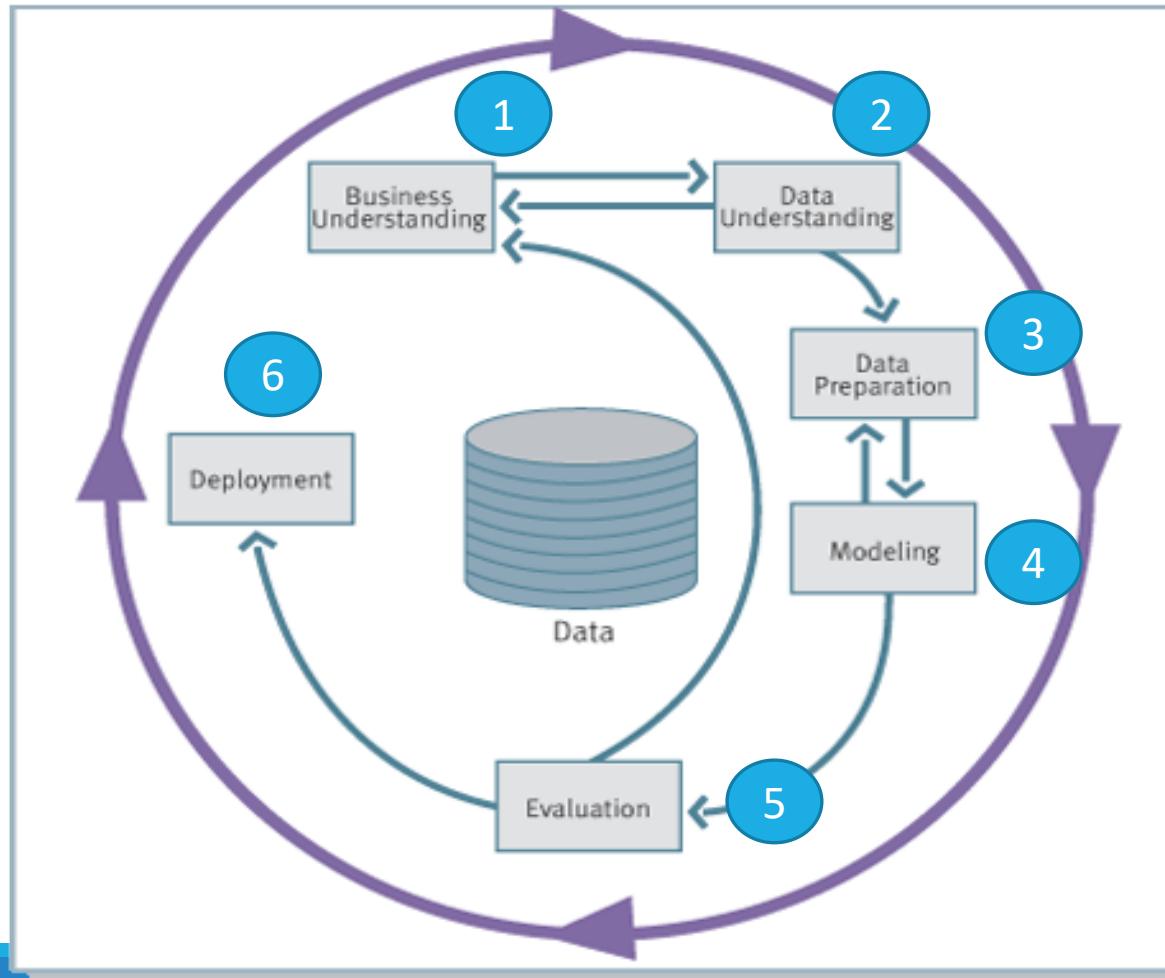
DATA MINING PROCESS

# 商业分析的基本原则

---

- 人类的决策和行为并非随机。
- 基于过往行为（历史数据）分析模式和关系。
- 依靠这些模式和关系来改进决策过程和业务成果

# 跨行业数据挖掘标准流程(CRISP-DM)



# Step 1: 商业/业务理解

---

商业/业务理解包括:

- 明确业务目标 Determine business objectives
- 状态评估 Assess situation
- 决定数据挖掘目标 Determine data mining goals
- 制作项目计划 Produce project plan

E-COMMERCE

Determine business objectives

?

# 商业/业务理解

明确业务目标

E-COMMERCE

场景评估

硬件/  
软件

人员

数据

大规模数据

大规模数据

客户浏览/  
购买数据

# 商业/业务理解

E-COMMERCE

明确业务目标

场景评估

数据挖掘目标

?

制作项目计划

# 项目目标示例

---

Phase	Time	Resources	Risks
Business understanding	1 week	All analysts	Economic change
Data understanding	3 weeks	All analysts	Data problems, technology problems
Data preparation	5 weeks	Data mining consultant, some database analyst time	Data problems, technology problems
Modeling	2 weeks	Data mining consultant, some database analyst time	Technology problems, inability to find adequate model
Evaluation	1 week	All analysts	Economic change, inability to implement results
Deployment	1 week	Data mining consultant, some database analyst time	Economic change, inability to implement results

# Step 2: 数据理解

对象及其属性的集合

属性是对象的属性或特性

- 例如：人的眼睛颜色、温度等。
- 属性也称为变量、字段、特性、维度或特征

属性集合是用来描述一个对象

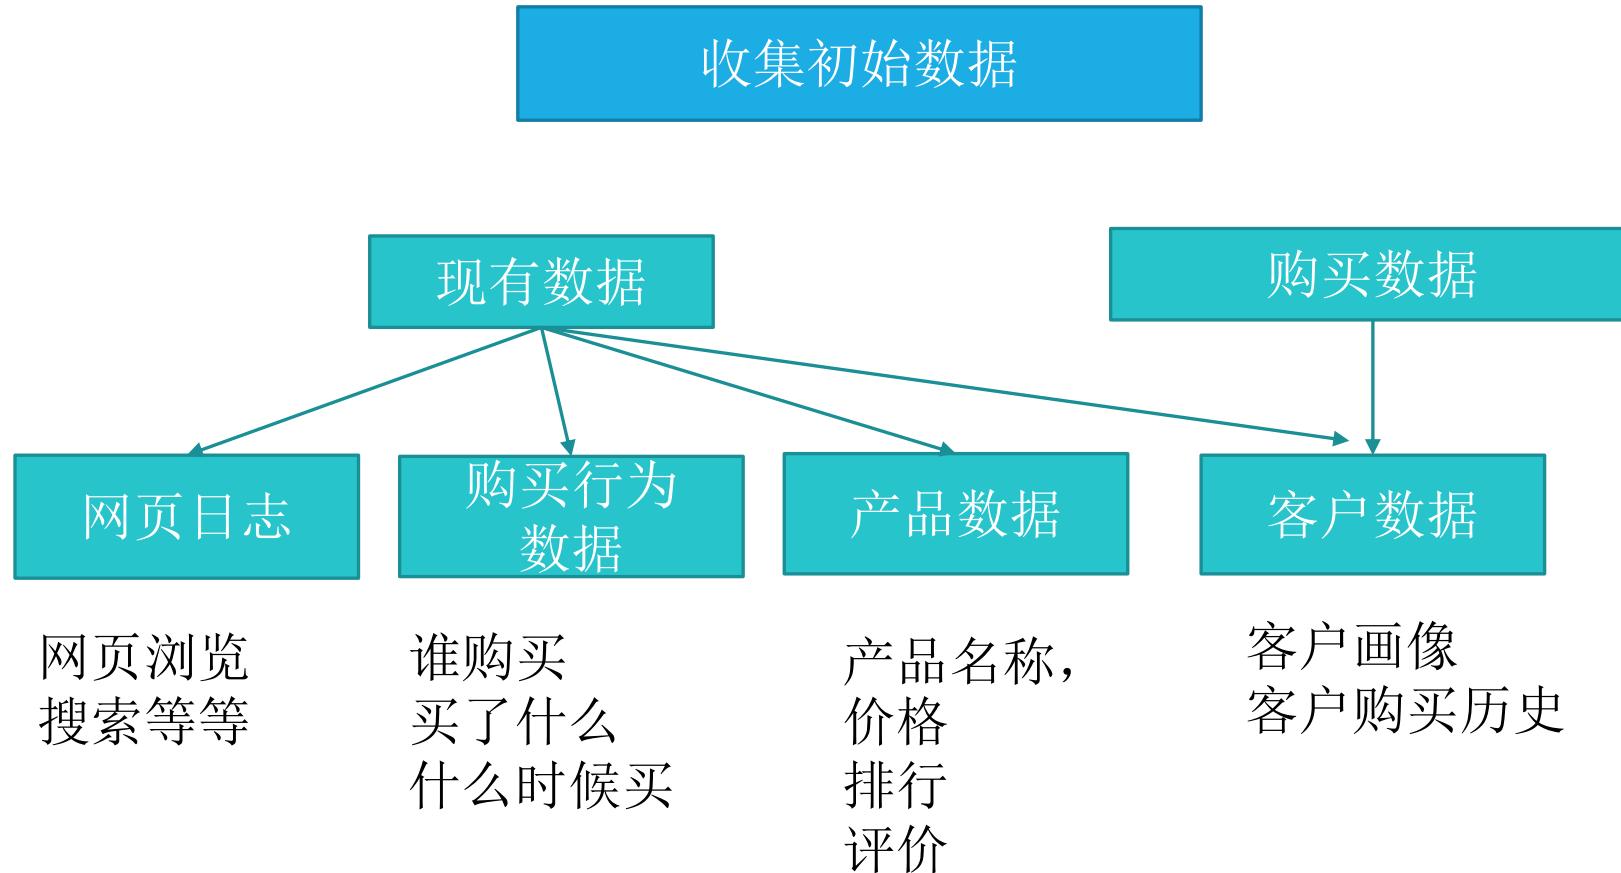
- 对象也称为记录、点、案例、样本、实体或实例

Attributes

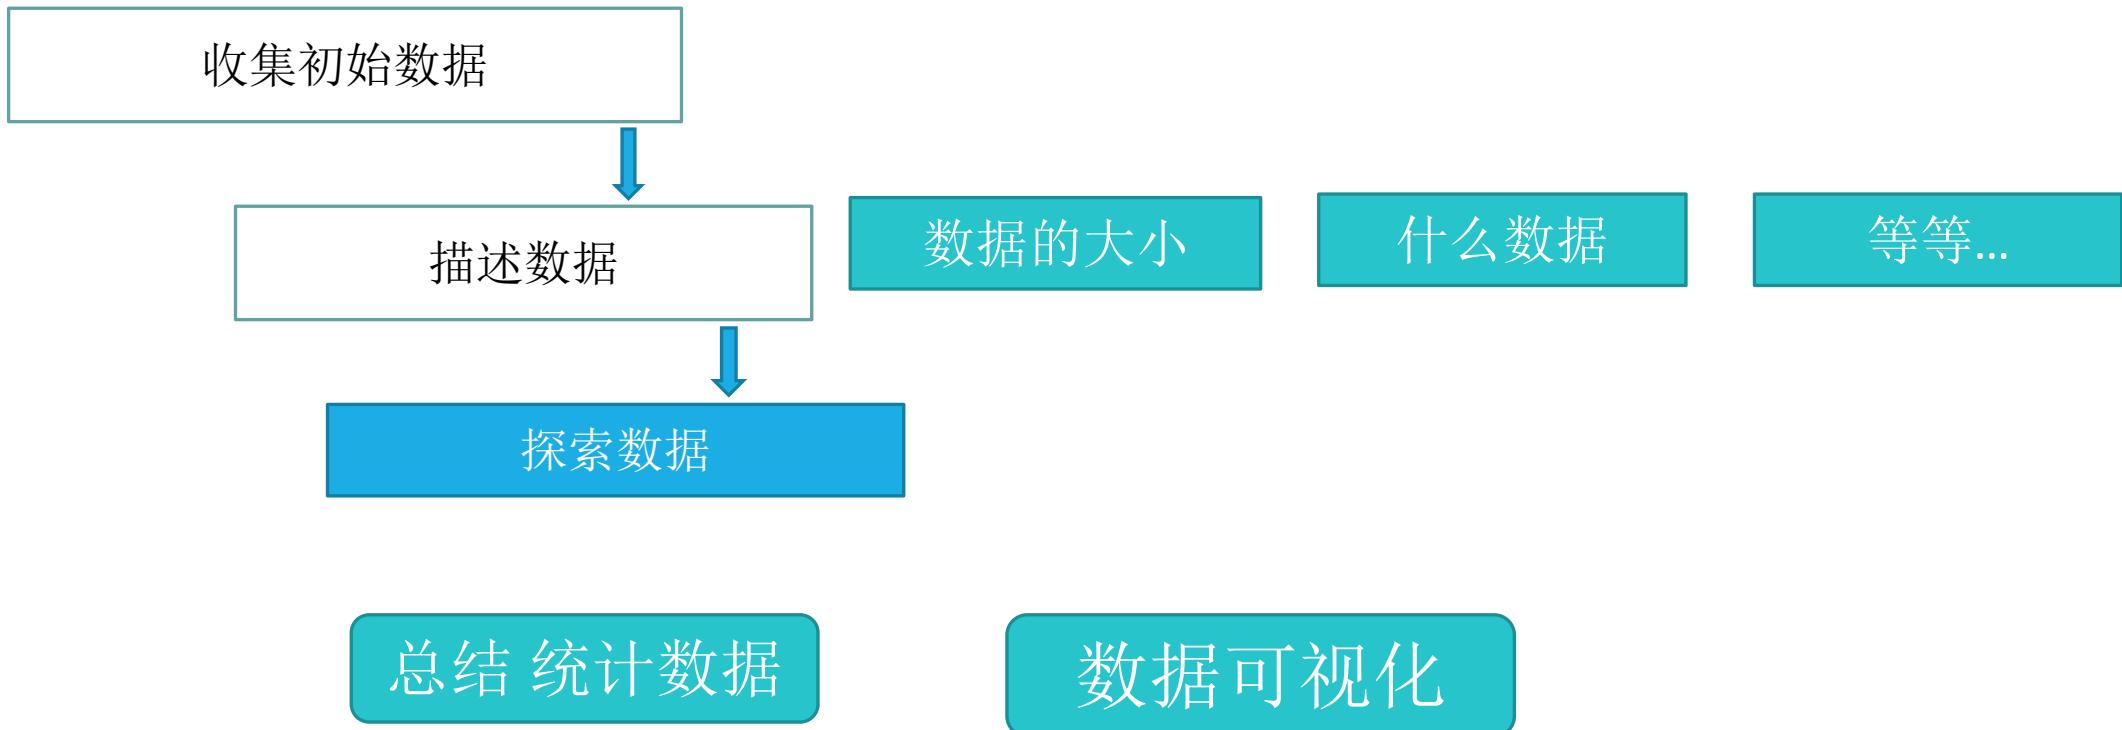
Objects

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

# 数据理解: 收集数据 Collect Data



# 数据理解: 探索数据



# Step 3: 数据准备 – 选择数据

---

选择观测值

- 抽样 Sampling

选择感兴趣的属性

- 选择正确的数据列: 特征工程
- 要包含哪些产品/客户属性

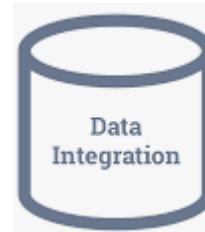


# 数据准备 – 数据清理

---

- 数据质量差会对许多数据处理工作产生负面影响
- 数据质量问题实际例子：
  - 噪音和异常值 Noise and outliers
  - 错误数据 Wrong data
  - 假数据 Fake data
  - 缺失数据 Missing values
  - 重复数据 Duplicate data

# 数据准备 – 整合数据



网页日志

购买行为  
数据

产品数据

客户数据

网页浏览  
网页搜索

收购买  
买了什么  
什么时候购买e

产品名称  
产品价格  
产品排名  
产品评价

客户画像  
客户购买记录

# Step 4: 建模 Model Building

---

- 模型 Model

$$Y = \textcolor{red}{f}(X)$$

数据挖掘目标 Data mining goal: 了解  $f$  功能  
函数是什么 learn what  $f$  function is

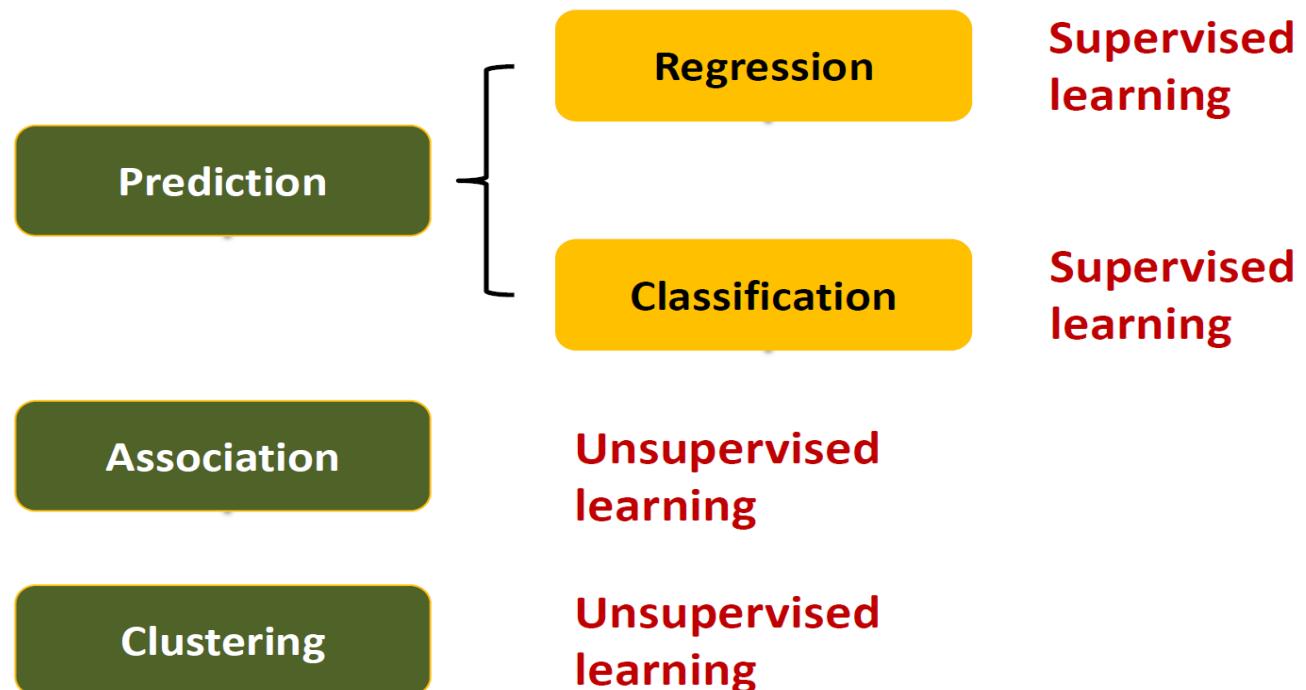
- 例子:

需求  $demand = f(\text{价格 } \textcolor{brown}{price})$

成绩  $grades = f(\text{学习小时 } \textcolor{brown}{hours studied})$

# 数据挖掘模型

模型任务：



# Step 5: 模型评估

预测 Prediction (监督学习 supervised learning)

回归分析 Regression

$$Y \text{ vs } \hat{Y} = f(X)$$

Metrics	Formula
Mean absolute error (MAE)	$\frac{1}{n} \sum_{i=1}^n  y_i - \hat{y}_i $
Mean squared error (MSE)	$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
Root mean squared error (RMSE)	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$

哪一个结果最佳?

Regression task	MSE
Model 1	0.04
Model 2	0.27
Model 3	0.13
Model 4	0.08

# 模型评估

二元分类的混淆矩阵 **Confusion matrix for binary classification**

	Actual 0	Actual 1
Predicted 0	True Negatives (TN)	False Negatives (FN)
Predicted 1	False Positives (FP)	True Positives (TP)

$$\text{准确度 Accuracy} = \frac{(TN + TP)}{(TN + FN + FP + TP)}$$

## Classification task Accuracy

Model 1	0.84
Model 2	0.92
<b>Model 3</b>	<b>0.94</b>
Model 4	0.89

# Step 6: 部署 Deployment

---

- 在部署阶段，数据挖掘的结果和数据挖掘技术被实际应用起来。  
例如，将预测模型应用于某些信息系统或业务流程：
  - 向被预测为特别有风险的客户发送特别优惠；  
在管理信息系统中使用欺诈检测模型，监控账户并创建“案例”进行审查